

Guia Completo do Aluno 1 — Contextualização + Análise Descritiva (Slides 1 e 2)

Objetivo deste documento: Permitir que você, Aluno 1, domine com segurança absoluta a abertura da apresentação do grupo. Você é o responsável por situar a banca no problema, explicar a origem dos dados do TSE e apresentar o diagnóstico das 4 variáveis que alimentarão os algoritmos de Machine Learning.

PARTE 1 — SLIDE 1: CONTEXTUALIZAÇÃO DO TRABALHO (~1.5 min)

1.1 Objetivo do Trabalho e Pergunta de Negócio

A Narrativa Central

Na abertura, evite começar diretamente listando números soltos. Comece contando **qual problema o grupo se propôs a resolver**:

"Em uma eleição para o Congresso Nacional, os candidatos competem em condições de igualdade ou existem abismos estruturais de recursos e perfil? Nosso objetivo é investigar se os candidatos a Deputado Federal no Nordeste se dividem em grupos socioeconômicos bem definidos ou se formam um continuum homogêneo."

O Problema sob a ótica de Machine Learning

- O aprendizado utilizado é **Não Supervisionado** (*Unsupervised Learning*).
- **Por que não supervisionado?** Porque os dados do TSE **não possuem um rótulo pré-definido** dizendo quem pertence a qual "tipo" de candidatura. O algoritmo precisa encontrar essa estrutura latente sozinho, a partir da geometria e das relações estatísticas das variáveis.
- **O Pipeline Completo:**
 1. Análise Descritiva e Diagnóstico de Distribuição (sua parte - Aluno 1)
 2. Particionamento Hierárquico por Bisecting K-Means (Aluno 2)
 3. Caracterização Sociodemográfica e Nomeação dos Arquétipos (Aluno 3)
 4. Validação por Regras de Associação e Detecção de Casos Atípicos (Aluno 4)

1.2 A População Analisada e a Base do TSE

Delimitação Exata da População

- **População:** Todos os **2.189 candidatos a Deputado Federal** registrados no Tribunal Superior Eleitoral (TSE) para as Eleições de 2026.

- **Recorte Geográfico:** Os 9 estados da Região Nordeste do Brasil:
 - Alagoas (AL)
 - Bahia (BA)
 - Ceará (CE)
 - Maranhão (MA)
 - Paraíba (PB)
 - Pernambuco (PE)
 - Piauí (PI)
 - Rio Grande do Norte (RN)
 - Sergipe (SE)
- **Cargo:** Deputado Federal (câmara baixa do legislativo federal, eleição proporcional de lista aberta).

As Fontes de Dados e o Pré-Processamento (Notebook 00)

Para construir a base final, o grupo realizou o cruzamento relacional de três tabelas oficiais do Portal de Dados Abertos do TSE (dadosabertos.tse.jus.br):

1. **Consulta Candidatos ([consulta_cand](#)):** Atributos cadastrais e demográficos (Nome, CPF, Data de Nascimento/Idade, Gênero, Grau de Instrução, Ocupação Declarada, Estado Civil, Cor/Raça, Partido e UF).
2. **Declaração de Bens ([bem_candidato](#)):** Cada linha é um item patrimonial declarado pelo candidato (imóveis, veículos, aplicações financeiras, dinheiro em espécie). O grupo agrupou e somou esses valores por candidato ([Total_Bens](#)).
3. **Prestação de Contas Eleitorais ([despesas_contratadas](#)):** Registro contábil das despesas financeiras formalmente contratadas durante a campanha eleitoral. O grupo consolidou essas despesas no atributo [Total_Despesas_Contratadas](#) .

Chave de Ligação: O cruzamento foi realizado via [SQ_CANDIDATO](#) (código sequencial único do candidato no TSE).

PARTE 2 — SLIDE 2: ANÁLISE DESCRITIVA DAS 4 VARIÁVEIS (~2.5 min)

2.1 Por que essas 4 Variáveis Foram Escolhidas?

O grupo selecionou 4 **variáveis quantitativas fundamentais** para atuar como *drivers* (motoras) da clusterização. Elas representam os dois grandes pilares da viabilidade eleitoral:

1. **Capital Humano e Pessoal:** [IDADE](#) e [ANOS_ESTUDO](#)
2. **Capital Econômico e Político:** [Total_Bens](#) (patrimônio próprio) e [Total_Despesas_Contratadas](#) (mobilização de campanha)

 **Conceito Chave:** Deixamos variáveis como Gênero, Raça, Partido e Ocupação **fora** da clusterização propositalmente! Elas foram reservadas para a etapa de **perfilamento sociodemográfico** (Aluno 3), permitindo validar se os grupos econômicos formados refletiam ou não clivagens sociais reais sem causar distorções na distância euclidiana.

2.2 Tabela Geral de Estatísticas Descritivas (Tenha na Ponta da Língua)

Esta tabela resume todo o seu segundo slide:

Variável	Média	Mediana	Desvio-Padrão	Mínimo	Máximo	Comportamento Estatístico
IDADE	48,1 anos	48,0 anos	11,4 anos	21 anos	81 anos	Simétrica, quase normal
ANOS_ESTUDO	13,8 anos	16,0 anos	3,1 anos	1 ano	16 anos	Alta concentração no topo (Superior)
Total_Bens	R\$ 1.050.412	R\$ 85.000	R\$ 3.245.190	R\$ 0	R\$ 48.330.000	Assimetria extrema, 43% zeros
Total_Despesas_Contratadas	R\$ 442.180	R\$ 35.800	R\$ 785.420	R\$ 0	R\$ 3.320.000	Bimodal, 26% zeros , cauda pesada

2.3 Diagnóstico Detalhado Variável por Variável

1. IDADE (Anos)

- **Média:** 48,1 anos | **Mediana:** 48,0 anos (média e mediana praticamente idênticas!).
- **Distribuição:** Forma de sino (quase gaussiana), variando de 21 anos (idade mínima legal para Deputado Federal no Brasil) até 81 anos.
- **Interpretação:** A política nordestina não é polarizada por extremos etários. O grosso dos concorrentes está na maturidade profissional (entre 38 e 58 anos). Não há necessidade de transformações matemáticas nessa variável.

2. ANOS_ESTUDO (Tempo de Instrução)

- **Como foi criada:** O TSE fornece graus de instrução nominais. Para alimentar algoritmos baseados em distância euclidiana, mapeamos os níveis para anos formais de escolaridade:
- **Lê e Escreve:** 1 ano
- **Ensino Fundamental Incompleto:** 4 anos | **Completo:** 8 anos
- **Ensino Médio Incompleto:** 9 anos | **Completo:** 11 anos
- **Ensino Superior Incompleto:** 13 anos | **Completo:** 16 anos
- **Distribuição:** Forte assimetria à esquerda.
- **O Dado Alarmante:** **58% dos candidatos possuem Ensino Superior Completo (16 anos).**
- **Interpretação:** Enquanto na população geral do Nordeste a taxa de ensino superior é inferior a 15%, entre os candidatos ela chega a quase 60%. O registro de candidatura já opera como um filtro social elitista.

3. TOTAL_BENS (Patrimônio Declarado)

- **A Discrepância Brutal:** Média de **R\$ 1,05 milhão**, contra uma Mediana de apenas **R\$ 85 mil!**
- **O Fenômeno dos Zeros (Zero-Inflated):** **43% dos candidatos (941 de 2.189) declararam patrimônio exatamente igual a R\$ 0,00!**
- **O Topo da Pirâmide:** No extremo oposto, candidatos declaram dezenas de milhões (como a candidata mais rica, com R\$ 48,3 milhões).

- **Tratamento:** Impossível utilizar os valores brutos em reais no K-Means, pois poucos milionários puxariam os centróides para o infinito. Aplicamos a transformação logarítmica:

$$\text{Total_Bens_Log} = \log(1 + \text{Total_Bens})$$

4. TOTAL_DESPESAS_CONTRATADAS (Gastos de Campanha)

- **Média:** R\$ 442 mil | **Mediana:** R\$ 35,8 mil.
- **O Fenômeno dos Zeros:** 26% dos candidatos (569 de 2.189) contrataram R\$ 0,00 em despesas!
- **Interpretação Política:** Um quarto dos candidatos são puramente **candidaturas cartoriais / de legenda** (existem no papel para cumprir cota partidária, mas não confeccionaram um santinho nem fizeram um ato de rua).
- **Bimodalidade:** Os dados se dividem claramente entre:
 1. Quem não gastou nada ou valores simbólicos (< R\$ 5.000);
 2. Quem recebeu grandes aportes do Fundo Eleitoral (FEFC) e gastou entre R\$ 500 mil e o teto legal de R\$ 3,32 milhões.
- **Tratamento:** Transformação $\log(1 + \text{Despesas})$.

2.4 As Relações Bivariadas Relevantes (Cruzar Informações)

No Slide 2, para demonstrar domínio analítico avançado, comente estes cruzamentos do notebook 01:

1. Patrimônio vs. Despesas (Correlação Fraca a Moderada):

- A correlação entre Bens (log) e Despesas (log) é de apenas **+0,38**.
- **Por que isso é fascinante?** Mostra que ter dinheiro próprio no bolso **não significa automaticamente** fazer campanha rica! Existem ricos que não gastam nada (o que virará o *Cluster Patrimônio Sem Campanha*), e existem candidatos sem patrimônio que gastam milhões viabilizados por fundo partidário (o que virará o *Cluster Financiados*).

2. Cota de Gênero:

- Em todos os estados nordestinos, a proporção de mulheres fica rigorosamente entre 31% e 34% (o mínimo legal obrigatório é 30%). No entanto, ao olharmos os gastos de campanha, as mulheres recebem desproporcionalmente menos recursos próprios, dependendo quase que exclusivamente de repasses públicos.

PARTE 3 — SIMULAÇÃO DE PERGUNTAS DA BANCA (Defesa Blindada)

P1: "Por que vocês aplicaram a transformação Log nas variáveis de Bens e Despesas?"

Sua Resposta: "Porque ambas possuem assimetria positiva extrema (right-skewed), onde a média é mais de dez vezes superior à mediana. No K-Means e Bisecting K-Means, a distância utilizada é a euclidiana. Se usássemos os valores brutos em reais, candidatos com dezenas de milhões de patrimônio distorceriam completamente os centróides, formando clusters unitários de outliers. O $\log(1+x)$ estabiliza a escala sem perder a ordem de grandeza, e o '+1' evita o problema matemático de calcular $\log(0)$ para os candidatos com bens ou despesas zerados."

P2: "O que significa dizer que os dados são 'Zero-Inflated'?"

Sua Resposta: "Significa que há uma concentração excessiva e estrutural de valores exatamente iguais a zero — no nosso caso, 43% em bens e 26% em despesas. Esses zeros não são dados faltantes (missing values), são informações substantivas reais: cidadãos que não possuem patrimônio registrado e candidatos que não executaram atos financeiros de campanha. Reconhecer esse fenômeno foi determinante para entender por que mais adiante o Apriori precisou de quartis zero-aware."

P3: "Por que criar a variável ANOS_ESTUDO em vez de usar o código original do TSE?"

Sua Resposta: "O código original do TSE é meramente administrativo e não reflete intervalos proporcionais (por exemplo, a distância entre Fundamental e Médio não é a mesma entre Médio e Superior). Além disso, o K-Means calcula distâncias geométricas e médias contínuas. Mapear o grau de instrução para anos formais de estudo (1 a 16 anos) transformou uma variável ordinal qualitativa em uma métrica intervalar contínua, permitindo que a geometria euclidiana operasse sem criar distorções artificiais."

P4: "Por que vocês não colocaram Gênero, Raça e Partido logo na clusterização inicial?"

Sua Resposta: "Porque misturar variáveis contínuas padronizadas com variáveis categóricas 'one-hot encoded' (0 ou 1) em algoritmos de distância euclidiana causa a chamada 'maldição da dimensionalidade' e perda da interpretabilidade física dos centróides. Adotamos o padrão metodológico de separar variáveis driver (as 4 financeiras e de capacitação) para formar os grupos e usar as variáveis demográficas para caracterizar e validar os grupos formados."

PARTE 4 — IMAGENS PRONTAS PARA O SEU BLOCO

No seu computador, todas as imagens foram organizadas com nomes intuitivos na pasta [images/](#)
[imagens_apresentacao/](#) :

Slide	O que colocar	Arquivo Principal (Grid)	Arquivos Separados Disponíveis
Slide 1	Mapa e Distribuição de Candidatos por Estado	images/imagens_apresentacao/slide1_01_candidatos_por_uf.png	—
Slide 2 (Destaque)	Grid 2x2 das 4 Variáveis da Clusterização	images/imagens_apresentacao/slide2_01_distribuicao_4_drivers_grid.png	slide2_02_hist_idade.png slide2_03_hist_grau_instrucao.png slide2_04_hist_total_bens_log.png slide2_05_hist_total_despesas_log.png
Slide 2	Boxplots de Outliers por Variável	images/imagens_apresentacao/slide2_06_boxplots_outliers.png	—
Slide 2	Distribuição de Despesas em Escala Log	images/imagens_apresentacao/slide2_07_distribuicao_despesas_log.png	—

PARTE 5 — COLA RÁPIDA DE 60 SEGUNDOS (Memorize)

- População:** 2.189 candidatos a Deputado Federal nos 9 estados do Nordeste em 2026.
- Fontes:** TSE (Candidaturas + Bens Declarados + Despesas Contratadas consolidadas por nós).
- Idade:** Média e mediana de 48 anos, perfeitamente simétrica.
- Instrução:** Super-elitizada, 58% possuem Ensino Superior Completo (16 anos de estudo).
- Bens:** Média R\$ 1M vs Mediana R\$ 85 mil — **43% têm patrimônio ZERO**.
- Despesas:** Média R\$ 442k vs Mediana R\$ 35,8k — **26% têm despesas ZERO** (candidaturas cartoriais).
- Solução:** Aplicamos $\log(1+x)$ em bens e despesas para conter a assimetria e permitir que o K-Means agrupe padrões sem ser distorcido por milionários.