

Roteiro Completo da Apresentação

Análise de Candidatos a Deputado Federal — Nordeste 2026 (TSE)

Tempo total: 15-20 minutos

Grupo: 4 integrantes

Narrativa: Contexto → Dados → Descritiva → Escolha de K → Clusters → Caracterização e nomeação → Regras de associação → Validação dos perfis → Anomalias → Conclusões

Divisão por Apresentador

Apresentador	Bloco	Seções	Tempo Estimado
Aluno 1	Slides 1-2	Contextualização + Análise Descritiva	~4 min
Aluno 2	Slide 3	Bisecting K-Means (escolha de K)	~4 min
Aluno 3	Slide 4	Caracterização dos Clusters + Nomeação	~4 min
Aluno 4	Slides 5-6-7	Apriori + Isolation Forest + Conclusão	~5-7 min

ALUNO 1 — Contextualização + Análise Descritiva (~4 min)

Slide 1: Contextualização do Trabalho (~1.5 min)

O que mostrar

- Slide com título do trabalho, nomes do grupo e mapa do Nordeste destacado

Script de fala

"Nosso trabalho analisa o perfil dos **2.189 candidatos a Deputado Federal no Nordeste** nas eleições de 2026, utilizando dados oficiais do **Tribunal Superior Eleitoral (TSE)**.

A região analisada compreende os **9 estados do Nordeste**: Alagoas, Bahia, Ceará, Maranhão, Paraíba, Pernambuco, Piauí, Rio Grande do Norte e Sergipe.

A base de dados do TSE integra informações cadastrais dos candidatos — como idade, gênero, raça, profissão e escolaridade — com dados financeiros: o **patrimônio pessoal declarado** (bens totais) e as **despesas de campanha contratadas**.

O objetivo do trabalho é aplicar técnicas de **aprendizado não supervisionado** — clusterização, regras de associação e detecção de anomalias — para identificar **perfis eleitorais distintos**, validar esses perfis com regras empíricas e encontrar candidatos com comportamento atípico."

Se o professor perguntar:

- "Por que o Nordeste?" → "Foi a região designada ao nosso grupo."
- "De onde vêm os dados?" → "Portal de Dados Abertos do TSE (dadosabertos.tse.jus.br). A base já vem pré-processada com junção de candidaturas, bens declarados e prestações de contas."

Slide 2: Análise Descritiva das 4 Variáveis (~2.5 min)

O que mostrar

1. **Histogramas das 4 Variáveis da Clusterização** — do notebook `01_analise_descritiva.ipynb` (Seção 3):
 - **Grid Unificado 2x2:** `images/imagens_apresentacao/slide2_01_distribuicao_4_drivers_grid.png` (ou `images/notebook1/02_distribuicao_4_drivers_clusterizacao.png`)
 - **Histogramas Individuais Separados:**
 - Idade: `images/imagens_apresentacao/slide2_02_hist_idade.png`
 - Grau de Instrução (Tempo de Estudo): `images/imagens_apresentacao/slide2_03_hist_grau_instrucao.png`
 - Patrimônio Declarado (log): `images/imagens_apresentacao/slide2_04_hist_total_bens_log.png`
 - Despesas Contratadas (log): `images/imagens_apresentacao/slide2_05_hist_total_despesas_log.png`
2. **Boxplots de Outliers** — `images/imagens_apresentacao/slide2_06_boxplots_outliers.png`
3. **Distribuição Bimodal de Despesas** — `images/imagens_apresentacao/slide2_07_distribuicao_despesas_log.png`
4. **Tabela de estatísticas descritivas** (pode montar um slide com estes números):

Variável	Média	Mediana	Mín	Máx	Observação-chave
Idade	48,1 anos	48 anos	21	81	Distribuição simétrica
Anos de Estudo	13,8 anos	16 anos	1	16	58% têm Superior Completo
Total de Bens	R\$ 1,05M	R\$ 85k	R\$ 0	R\$ 48,3M	43% declararam R\$ 0
Despesas Contratadas	R\$ 442k	R\$ 35,8k	R\$ 0	R\$ 3,32M	26% com R\$ 0

Script de fala

"Antes de aplicar qualquer algoritmo, precisamos entender os dados. As **4 variáveis que usaremos na clusterização** são: idade, anos de estudo, total de bens declarados e total de despesas de campanha contratadas.

A **idade** tem distribuição simétrica com média de 48 anos — o cenário político nordestino não é dominado por jovens nem por idosos.

A **escolaridade** é fortemente concentrada no topo: 58% dos candidatos têm ensino superior completo. Isso reflete uma barreira de entrada na política institucional.

Já o **patrimônio** apresenta uma assimetria brutal: **43% dos candidatos declararam R\$ 0 em bens**. A mediana é de apenas R\$ 85 mil, mas a média é de R\$ 1 milhão — puxada por uma elite financeira.

As **despesas de campanha** mostram um padrão bimodal: **26% não registraram nenhum gasto** — são candidaturas que provavelmente não se ativaram — enquanto outra parcela recebeu investimentos substanciais dos fundos partidário e eleitoral.

A observação dos zeros é crucial: são candidatos reais que existem no sistema eleitoral, mas com perfis financeiros radicalmente diferentes. Essa heterogeneidade vai ser determinante na formação dos clusters."

Se o professor perguntar:

- **"Por que usaram log?"** → "As variáveis financeiras têm distribuição extremamente assimétrica (média >> mediana). A transformação $\log(1+x)$ estabiliza a variância e permite que o algoritmo de clusterização não seja dominado por poucos outliers milionários."
- **"O que é zero-inflated?"** → "É quando uma proporção grande dos dados tem valor exatamente zero. No nosso caso, 43% de bens zerados e 26% de despesas zeradas. Isso cria uma bimodalidade que precisa ser tratada com cuidado."
- **"ANOS_ESTUDO existia na base original?"** → "Não. O TSE fornece o grau de instrução como texto (ex.: 'Ensino Superior Completo'). Nós criamos a variável numérica ANOS_ESTUDO mapeando cada grau para o número de anos correspondente (ex.: Superior Completo = 16, Ensino Médio = 11, Fundamental = 8), para poder usar na clusterização."

ALUNO 2 — Clusterização com Bisecting K-Means (~4 min)

Slide 3: Escolha de K e Bisecting K-Means (~4 min)

O que mostrar (do notebook [02_clusterizacao.ipynb](#))

1. **Gráfico de Cotovelo + Curva de Silhueta** — seção V3.1
2. **Tabela de métricas por K** (montar no slide):

K	Silhouette	Davies-Bouldin	Calinski-Harabasz
2	0.446	1.219	1.391
3	0.380	1.048	1.701

K	Silhouette	Davies-Bouldin	Calinski-Harabasz
4	0.488 ★	0.844 ★	2.429 ★
5	0.435	0.932	2.115
6	0.395	0.924	1.990

1. **Árvore de divisão do Bisecting K-Means** — seção V3.2
2. **Gráfico de barras K-Means vs Bisecting** — seção V3.2.1

Script de fala

"Para a clusterização, utilizamos o **Bisecting K-Means** conforme orientado, e testamos valores de K de 2 a 8.

Avaliamos cada K com **três métricas formais**:

- O **Coefficiente de Silhueta**, que mede a qualidade da separação entre clusters — quanto maior, melhor.
- O **Índice Davies-Bouldin**, que mede a sobreposição entre clusters — quanto menor, melhor.
- O **Calinski-Harabasz**, que mede a razão entre a dispersão inter-cluster e intra-cluster — quanto maior, melhor.

K = 4 é o ótimo indiscutível nas três métricas: Silhueta máxima de **0,488**, Davies-Bouldin mínimo de **0,844** e Calinski-Harabasz máximo de **2.429**.

O **método do cotovelo** confirma: a inércia cai de forma acentuada até K=3 e K=4, estabilizando depois.

O **Bisecting K-Means** opera de forma *top-down*: começa com todos os 2.189 candidatos em um único grupo e vai dividindo o cluster de maior inércia em cada nível. Na prática, as divisões foram:

- Nível 1: a raiz se dividiu em 2 grupos (1.034 e 1.155 candidatos);
- Nível 2: o grupo de 1.034 se dividiu em 573 e 461;
- Nível 3: o grupo de 573 se dividiu em 326 e 247.

Os tamanhos finais (1.155, 461, 326, 247) são **praticamente idênticos** aos do K-Means padrão (1.153, 460, 328, 248). Essa **convergência estrutural** entre dois algoritmos independentes valida que K=4 não é um artefato de um método específico.

A silhueta do Bisecting (0,485) é virtualmente igual à do K-Means (0,488). Escolhemos **K=4** com confiança total."

Se o professor perguntar:

- **"Por que não K=3 ou K=5?"** → "K=3 tem silhueta menor (0,380) e Davies-Bouldin pior (1,048). K=5 piora em todas as métricas. K=4 é pico simultâneo nos 3 indicadores."
- **"Qual a diferença entre K-Means e Bisecting?"** → "O K-Means particiona todos os pontos simultaneamente; o Bisecting é hierárquico e divisivo — divide de cima pra baixo. O fato de ambos convergirem para a mesma partição mostra que a estrutura de 4 clusters é intrínseca aos dados."

- "E o método do cotovelo sozinho?" → "O cotovelo tem interpretação visual subjetiva — por isso complementamos com métricas objetivas (Silhueta, DB, CH) que apontam unânime para K=4."

ALUNO 3 — Caracterização e Nomeação dos Clusters (~4 min)

Slide 4: Perfis dos Clusters + Nomeação (~4 min)

 O que mostrar (do notebook [02_clusterizacao.ipynb](#))

1. **Gráfico de Radar Polar** — seção V3.3 (sobreposição dos 4 clusters nos 4 eixos)
2. **Ficha técnica com medianas** (montar no slide):

Cluster	n	Mediana Bens	Mediana Despesas	Mediana Idade	Escolaridade	% Mulheres
 Estruturados	1.153 (52,7%)	R\$ 400k	R\$ 159k	49 anos	Superior	27,6%
 Financiados	460 (21,0%)	R\$ 0	R\$ 33,6k	44 anos	Superior	51,5%
 Base Simbólica	328 (15,0%)	R\$ 0	R\$ 0	46 anos	Médio	50,3%
 Patr. Sem Campanha	248 (11,3%)	R\$ 140k	R\$ 0	55 anos	Médio/ Superior	24,2%

1. **Heatmap de Z-Score** — seção V3.4 (desvios padronizados de cada cluster)
2. **Heatmap de Ocupações** — seção V3.4 (Top 10 profissões por cluster)

Script de fala

"Definido K=4, precisamos entender **quem são** esses grupos. Nomeamos provisoriamente como Clusters A, B, C e D e analisamos tanto as 4 variáveis quantitativas quanto variáveis categóricas como gênero, raça e profissão.

Cluster A — Estruturados (1.153 candidatos, 52,7%):

É o maior grupo. Patrimônio mediano de R\$ 400 mil, despesas de campanha de R\$ 159 mil. Concentra **100% dos deputados** em exercício, advogados, médicos e vereadores. É a **máquina eleitoral institucional** — candidatos que combinam patrimônio pessoal com alto investimento em campanha. 72% homens, 43% brancos.

Cluster B — Base Simbólica (328 candidatos, 15%):

Patrimônio zero, despesas zero. São candidaturas que existem formalmente mas **não se ativaram financeiramente**. Predominam estudantes, agricultores e profissões de

subsistência. 72% negros/pardos, 50% mulheres. O partido DC concentra 4,5x mais candidatos aqui do que a média.

Cluster C — Financiados (460 candidatos, 21%):

Patrimônio zero, mas com despesas medianas de R\$ 33,6 mil. São candidatos **sem recursos próprios que receberam aportes dos partidos**. Destaque: **51,5% são mulheres** — evidência direta do impacto da política de cotas de financiamento feminino. 71% negros/pardos.

Cluster D — Patrimônio Sem Campanha (248 candidatos, 11,3%):

O inverso dos Financiados: patrimônio mediano de R\$ 140 mil, mas despesas **zeradas**. São candidatos com recursos próprios que **não investiram na campanha**. O grupo mais idoso (mediana 55 anos), com **21,5% de advogados** e **30,8% de empresários** — a maior taxa da eleição. 76% homens."

Se o professor perguntar:

- **"Por que esses nomes?"** → "Cada nome sintetiza a combinação única de patrimônio + despesa que define o cluster. 'Estruturados' = tem tudo; 'Financiados' = não tem bens mas recebe campanha; 'Base Simbólica' = não tem nada (candidatura formal); 'Patrimônio Sem Campanha' = tem bens mas não gasta."
- **"E o gênero?"** → "O dado mais surpreendente é que o Cluster Financiados é o único com maioria feminina (51,5%), sugerindo que as políticas de cota de financiamento para candidatas estão direcionando recursos a mulheres sem patrimônio próprio."
- **"E a raça?"** → "Branços são super-representados nos Estruturados (43% vs 27% na base geral). Pretos e pardos dominam a Base Simbólica (72%) e os Financiados (71%)."

ALUNO 4 — Regras de Associação + Anomalias + Conclusão (~5-7 min)

Slide 5: Regras de Associação — Apriori (~2.5 min)

O que mostrar (do notebook [03_regras_associacao.ipynb](#))

1. Tabela de variáveis utilizadas (montar no slide):

- Categóricas: `SG_PARTIDO`, `DS_GENERO`, `DS_GRAU_INSTRUCAO`, `DS_ESTADO_CIVIL`, `DS_COR_RACA`, `DS_OCUPACAO`
- Contínuas em quartis: `Faixa_Idade` (4 quartis), `Faixa_Estudo` (4 faixas por grau de instrução), `Faixa_Bens` (quartis zero-aware), `Faixa_Despesa_Contratada` (quartis zero-aware)
- Alvo: `cluster` (os 4 arquétipos)

2. Tabela de regras com cluster no consequente — Cell 19:

Características → Cluster	Confiança	Lift	n
Sem Bens + Sem Despesa → Base Simbólica	100%	6,67	308
Bens Q2 (médio) + Sem Despesa → Patrimônio Sem Campanha	100%	8,83	63
Bens Q3 (alto) + Sem Despesa → Patrimônio Sem Campanha	100%	8,83	48
Bens Q3 (alto) + Despesa Q3 (alta) → Estruturados	100%	1,90	282
Bens Q2 (médio) + Despesa Q3 (alta) → Estruturados	100%	1,90	142
Sem Bens + Despesa Q3 (alta) → Financiados	100%	4,76	49
Sem Bens + Despesa Q2 (média) → Financiados	100%	4,76	167

1. **Grafo interativo** — print/screenshot do [grafo_regras_cluster.html](#)
2. **Tabela de regras com cluster no antecedente** — Cell 23:

Cluster → Característica	Confiança	Lift
Estruturados → DS_OCUPACAO=DEPUTADO	7,2%	1,83
Estruturados → Despesa Q3 (alta)	42,9%	1,73
Estruturados → Bens Q3 (alto)	36,8%	1,70
Financiados → Sem Bens	98,7%	2,80
Financiados → Despesa Q1 (baixa)	52,4%	2,11
Financiados → DS_GENERO=FEMININO	51,5%	1,37
Base Simbólica → SG_PARTIDO=DC	14,0%	4,51
Base Simbólica → Sem Despesa	97,3%	3,82
Base Simbólica → Sem Bens	96,6%	2,74
Patrimônio Sem Campanha → Sem Despesa	96,0%	3,77
Patrimônio Sem Campanha → Bens Q1 (baixo)	53,6%	2,48

1. **Grafo de antecedente fixo** — print/screenshot do [grafo_regras_antecedente_fixo.html](#)

Script de fala

"Na etapa de regras de associação, usamos o algoritmo **Apriori** para verificar se os nomes que demos aos clusters fazem sentido empírico.

As **variáveis contínuas foram transformadas em quartis**: idade em 4 faixas iguais por quartis; escolaridade em 4 faixas baseadas nos graus de instrução reais; e patrimônio e despesas em **quartis zero-aware** — separamos os valores zerados como categoria própria e calculamos quartis sobre os valores positivos, já que 43% dos bens e 26% das despesas são zero.

O Apriori minerou **126 mil regras** a partir de 8.231 itemsets frequentes. Filtramos para analisar as mais relevantes.

Direção 1: Características → Cluster

Todas as regras que apontam para os clusters têm **100% de confiança**:

- Quem tem **sem bens E sem despesas** → 100% Base Simbólica (lift 6,67, 308 candidatos).
- Quem tem **bens no quartil médio ou alto E sem despesas** → 100% Patrimônio Sem Campanha (lift 8,83 — o maior da base!).
- Quem tem **bens Q2 ou Q3 E despesas Q3** → 100% Estruturados.
- Quem tem **sem bens E despesas Q2 ou Q3** → 100% Financiados.

Ou seja: se você me disser quanto um candidato declarou de patrimônio e quanto gastou, eu sei com 100% de certeza em qual cluster ele está.

Direção 2: Cluster → Características

Invertendo a análise, cada cluster revela seu DNA sociopolítico:

- **Estruturados** → associados a Deputados (lift 1,83), partido PP, médicos e vereadores.
- **Financiados** → associados a Sem Bens (lift 2,80), partido MISSÃO (lift 2,06) e **51,5% mulheres** (lift 1,37).
- **Base Simbólica** → associados ao partido DC (lift 4,51), sem despesas (lift 3,82), e escolaridade até fundamental (lift 1,93).
- **Patrimônio Sem Campanha** → associados a sem despesas (lift 3,77), bens Q1 e Q2, homens (76%).

Conclusão: os nomes confirmam. As regras de associação validam matematicamente cada arquétipo."



Se o professor perguntar:

- **"Por que não quartis puros para bens e despesas?"** → "Porque 43% dos candidatos declararam bens = R\$ 0 e 26% têm despesas = R\$ 0. Se usássemos pd.qcut puro com 4 faixas, os dois primeiros quartis colapsariam em zero, perdendo todo o poder discriminativo. A abordagem zero-aware separa os zeros como categoria semântica e calcula quartis sobre quem de fato possui valores positivos."
- **"O que é lift?"** → "Lift mede quantas vezes mais frequente a regra é em relação ao esperado se as variáveis fossem independentes. Lift = 8,83 significa que a combinação 'bens médios/altos + sem despesas' aparece 8,83 vezes mais frequentemente no Patrimônio Sem Campanha do que seria esperado por chance."
- **"O que significam essas regras na prática?"** → "Que os clusters NÃO são artefatos do algoritmo — são padrões reais. As combinações de atributos socioeconômicos dos candidatos se alinham perfeitamente aos perfis que nomeamos."

Slide 6: Detecção de Anomalias — Isolation Forest (~2 min)

 O que mostrar (do notebook [04_deteccao_anomalias.ipynb](#))

1. Tabela de contaminação testada — Cell 16:

Contamination	Atípicos	%
0.01	22	1,0%
0.02	44	2,0%
0.03 ★	66	3,0%
0.05	110	5,0%
auto	792	36,2%

1. Tabela de top anomalias globais — Cell 20 (mostrar 5-8 nomes mais interessantes)

2. Gráfico 2D de dispersão com anomalias destacadas — Cell 22

3. Resumo anomalias por cluster — Cell 26+:

- Estruturados: 35 atípicos
- Financiados: 14 atípicos
- Base Simbólica: 10 atípicos
- Patrimônio Sem Campanha: 8 atípicos

Script de fala

"Na última etapa, aplicamos o **Isolation Forest** para detectar candidatos com comportamento atípico. O Isolation Forest constrói árvores de isolamento aleatórias: quanto mais fácil é isolar um ponto do restante, mais anômalo ele é.

Valor de contaminação: 3% (0.03). Testamos de 1% a 8% e o modo 'auto' do scikit-learn. O modo auto sinalizou **36% da base** (792 candidatos!) — totalmente impraticável. Optamos por 3%, que identifica **66 candidatos atípicos** — um volume focado para auditoria individual.

Anomalias na população completa — os casos mais extremos:

- **Nathalia Pedrosa** (PE): 25 anos, Superior Incompleto, **R\$ 48,3 milhões em bens** e R\$ 0 de despesas. O maior patrimônio de toda a eleição no Nordeste, numa candidata de 25 anos que não gastou nada em campanha.
- **Tiririca** (CE): candidato que *lê e escreve* (1 ano de estudo), mas com R\$ 2,45 milhões em despesas. A anomalia dele é *educacional* — ele aparece no meio da nuvem 3D porque a dimensão que o torna atípico (escolaridade) não tem eixo visual no gráfico tridimensional.

Anomalias dentro de cada cluster — candidatos que quebram a lógica do próprio grupo:

- Nos **Financiados**: candidatos com pequenos bens declarados (R\$ 240, R\$ 389) quando 98,7% do grupo tem R\$ 0. São desvios mínimos em valor absoluto, mas enormes em relação ao padrão do cluster (z-score > 9,0).
- Na **Base Simbólica**: candidatos que registraram despesas residuais (R\$ 48, R\$ 100, R\$ 390) quando 97% do grupo tem despesa zero.

- **37 candidatos** são atípicos **somente dentro do seu cluster** — na análise global, passariam despercebidos."

Se o professor perguntar:

- **"Por que 3% e não 5%?"** → "Com 5% teríamos 110 atípicos — volume alto que dilui o foco. Com 3% capturamos os 66 mais extremos, mantendo a inspeção substantiva e focada."
- **"Por que algumas anomalias aparecem no centro do gráfico 3D?"** → "Porque o Isolation Forest foi treinado em 4 dimensões, mas o gráfico 3D mostra apenas 3 eixos (Idade, Bens, Despesas). A 4ª dimensão — escolaridade — está oculta visualmente. Candidatos cujo isolamento é puramente educacional (como Tiririca, com escolaridade $z=-4,1$) projetam-se no centro da nuvem 3D. É por isso que adicionamos um tooltip diagnóstico que explica o motivo de cada anomalia."
- **"Qual a diferença entre anomalia global e por cluster?"** → "A global compara contra toda a base de 2.189 candidatos. A por cluster compara contra os pares do mesmo grupo. Um candidato dos Financiados com R\$ 240 em bens é 'normal' na população geral, mas é um outlier extremo dentro do seu grupo onde 98,7% tem bens = R\$ 0."

Slide 7: Conclusão (~1.5 min)

O que mostrar

- Slide-resumo com os 4 arquétipos e os achados principais

Script de fala

"Para concluir, nossos principais achados:

1. Identificamos 4 perfis eleitorais distintos no Nordeste:

- Os **Estruturados** (53%) — a máquina eleitoral consolidada com patrimônio e campanha ativa.
- Os **Financiados** (21%) — candidatos sem patrimônio pessoal que recebem aportes dos partidos.
- A **Base Simbólica** (15%) — candidaturas formais sem mobilização financeira.
- O **Patrimônio Sem Campanha** (11%) — candidatos com bens que não investem em campanha.

2. O que confirmou nossas expectativas:

- Que a elite política tem alto patrimônio e alto gasto — os Estruturados.
- Que muitas candidaturas são apenas formais, para preenchimento de nominata — a Base Simbólica.

3. O que foi inesperado:

- O **Cluster Financiados tem maioria feminina (51,5%)**. Isso é evidência direta de que as cotas de financiamento para candidatas estão redirecionando recursos a mulheres sem patrimônio próprio — uma política pública deixando rastro nos dados.
- O **Cluster Patrimônio Sem Campanha**: empresários e advogados com bens declarados que não gastaram nada em campanha. Por que se candidatam? É uma pergunta que os dados revelam mas não respondem.

4. A principal contribuição:

As regras de associação com **100% de confiança** em todos os clusters mostram que os perfis não são artefatos do algoritmo — são padrões reais e interpretáveis da dinâmica eleitoral nordestina. E a detecção de anomalias revelou 37 candidatos que só são atípicos dentro do seu grupo — invisíveis na análise global, mas significativos quando comparados aos seus pares.

Obrigado!"



Se o professor perguntar:

- **"Qual a principal contribuição do trabalho?"** → "Mostrar que a combinação patrimônio × despesas de campanha revela 4 arquétipos eleitorais com perfis sociodemográficos e ocupacionais completamente distintos — e que esses perfis são válidos por regras de associação com 100% de confiança."
- **"Se fizessem de novo, o que mudariam?"** → "Incluiríamos o resultado da eleição (eleito/não eleito) quando disponível para testar se algum perfil tem vantagem competitiva. Também exploraríamos variáveis como número do candidato na urna e coligações."



Checklist Final Antes da Apresentação

- [] Verificar que todos os gráficos estão renderizados nos notebooks (recarregar abas)
- [] Preparar prints/screenshots dos gráficos-chave para os slides
- [] Cada aluno lê e ensaia seu bloco pelo menos 2x
- [] Testar se os grafos HTML ([grafo_regras_cluster.html](#) e [grafo_regras_antecedente_fixo.html](#)) abrem no navegador
- [] Preparar para perguntas cruzadas — o professor pode perguntar qualquer parte a qualquer aluno



Mapa de Imagens Prontas para a Apresentação

Todas as imagens foram salvas em alta resolução (300 DPI) e organizadas por pasta para inserção direta nos slides:

Slide	Tema / Gráfico	Arquivo Principal	Arquivo na Pasta de Apresentação
Slide 1	Síntese de Candidatos por Estado	images/notebook0/01_candidatos_por_uf_preparados.png	images/imagens_apresentacao/slide1_01_candidatos.png
Slide 2	Grid das 4 Variáveis da Clusterização	images/notebook1/02_distribuicao_4_drivers_clusterizacao.png	images/imagens_apresentacao/slide2_01_distribuicao.png
Slide 2	Histograma 1: Idade (Simétrica)	images/notebook1/hist_01_idade.png	images/imagens_apresentacao/slide2_02_hist_idade.png
Slide 2	Histograma 2: Grau de	images/notebook1/hist_02_grau_instrucao.png	images/imagens_apresentacao/slide2_03_hist_grau.png

Slide	Tema / Gráfico	Arquivo Principal	Arquivo na Pasta de Ap
	Instrução (58% Superior)		
Slide 2	Histograma 3: Bens em Log (43% com R\$ 0)	images/notebook1/hist_03_total_bens_log.png	images/imagens_apr slide2_04_hist_tot
Slide 2	Histograma 4: Despesas em Log (26% com R\$ 0)	images/notebook1/hist_04_total_despesas_contratadas_log.png	images/imagens_apr slide2_05_hist_tot
Slide 2	Boxplots de Outliers por Variável	images/notebook1/03_boxplots_variaveis_numericas.png	images/imagens_apr slide2_06_boxplots
Slide 2	Distribuição de Despesas (log) Zoom	images/notebook1/18_distribuicao_despesas_log.png	images/imagens_apr slide2_07_distribui
Slide 3	Cotovelo, Silhueta, DB e CH (\$k=4\$)	images/notebook2/17_v3_metricas_cotovelo_silhouette_db_ch.png	
Slide 3	Árvore e Queda de Inércia Bisecting	images/notebook2/18_v3_bisecting_arvore_e_inercia.png	
Slide 3	Comparação K-Means vs Bisecting	images/notebook2/19_v3_comparacao_silhouette_kmeans_vs_bisecting.png	
Slide 4	Radar Polar Multidimensional dos 4 Clusters	images/notebook2/20_v3_radar_polar_multidimensional.png	
Slide 4	Top 10 Ocupações por Cluster (Heatmap)	images/notebook2/24_v3_top10_ocupacoes_heatmap.png	
Slide 4	Assinatura de Desvio Z-Score	images/notebook2/25_v3_assinatura_desvio_zscore.png	
Slide 4	Matriz de Transição V2 → V3	images/notebook2/26_v3_matriz_transicao_v2_vs_v3.png	
Slide 5	Distribuição dos Quartis das 4 Variáveis	images/notebook3/01_distribuicao_quartis.png	
Slide 5	Top Regras: Características → Cluster	images/notebook3/02_top_regras_cluster_consequente.png	
		images/notebook3/03_top_regras_cluster_antecedente.png	

Slide	Tema / Gráfico	Arquivo Principal	Arquivo na Pasta de Ap
Slide 5	Top Regras: Cluster → Características (DNA)		
Slide 5	Grafo de Rede Interativo (Cluster)	images/notebook3/grafico_regras_cluster.html	
Slide 6	Projeções 2D dos Candidatos Atípicos	images/notebook4/03_anomalias_globais_2d.png	
Slide 6	Gráfico 3D das Anomalias (PNG Estático)	images/notebook4/04_grafico_3d_anomalias_matplotlib.png	
Slide 6	Gráfico 3D Interativo Global (HTML)	images/notebook4/04_grafico_3d_anomalias_global.html	
Slide 6	Gráfico 3D Interativo por Cluster (HTML)	images/notebook4/05_grafico_3d_anomalias_cluster.html	
Slide 6	Matriz de Contingência (Global vs Local)	images/notebook4/06_matriz_contingencia_anomalias.png	

Pacotes ZIP para Download Direto:

- Todas as imagens unificadas: [images/todas_as_imagens.zip](#) (24,8 MB)
- Por notebook: [images/notebook0.zip](#) , [images/notebook1.zip](#) , [images/notebook2.zip](#) , [images/notebook3.zip](#) , [images/notebook4.zip](#)